

BAB 9 — AI Evaluation Why AI yang melanggar Alpha Promise tidak akan crash sistem—ia hanya akan diam-diam merusak disiplin trader. Evaluasi tradisional (unit test) tidak cukup; kita perlu mengukur kualitas "kecoaching-an" AI.

What — Metrik Evaluasi AI

Hallucination Rate: Apakah AI mengklaim tahu sesuatu yang tidak ada di konteks? (misal: merujuk trade yang tidak ada). AI tidak boleh mengarang trade, pattern, memory, maupun insight yang tidak berasal dari Context Builder (Bab 4). Reflection Quality Score: Diukur menggunakan kombinasi indikator kuantitatif (panjang respons, completion rate, follow-up engagement) dan sampling evaluasi manual. Panjang respons tidak boleh menjadi satu-satunya indikator kualitas refleksi. Coaching Quality: Apakah AI bertanya, bukan memberi perintah? Guardrail Violation Rate: (Golden Signal - Bab 24) Seberapa sering Output Guardrail terpicu? How — Success Metrics & Evaluation Loop

Automated: Guardrail Test Suite dijalankan di CI/CD. Semi-Automated: Logging menunjukkan jika AI memberi pertanyaan tertutup (Yes/No). Manual (Human-in-the-loop): Sampel percakapan direview oleh tim psikolog/trader expert setiap sprint untuk menilai tone dan empathy. Best Practice Definisikan "Success" bukan sebagai "AI menjawab benar", tapi "User menjadi lebih aware setelah sesi chat". Metrik proksi: rasio user yang mengubah perilaku tradingnya setelah diberitahu tentang Reflection Gap.

Trade-off Evaluasi manual (human review) sangat lambat dan tidak skalabel. Evaluasi otomatis (LLM-as-a-judge) mahal dan bisa bias. Untuk MVP, fokus pada Guardrail Violation Rate (otomatis, kritis) dan sampling manual 1% sesi chat.

Recommendation Buat dashboard internal khusus yang menampilkan: Hallucination indicator, Guardrail Violation, dan Average Reflection Quality per hari. Dashboard ini menjadi salah satu Golden Signal operasional dan direview pada akhir setiap sprint bersama Prompt Registry. Ini menjadi masukan utama untuk iterasi Prompt Template (Bab 4).

BAB 10 — AI Roadmap Why AI yang terlalu ambisius di awal akan gagal diimplementasi. Kita harus membangun Memory dan Guardrail dulu sebelum Coaching yang canggih bisa dilakukan. AI Roadmap tidak berdiri sendiri; seluruh milestone AI wajib mengikuti urutan Development Roadmap (Arch Bible Bab 26) sehingga tidak ada kemampuan AI yang dibangun di atas fondasi platform yang belum stabil.

What — Fase AI

MVP (Fase 1-2): L0 & L1 Memory. Socratic Coaching statis (8 template). Guardrail dual-layer. GPT-4o-mini untuk summary. Fast Follow (Fase 3): L2 Trader Digest aktif. Reflection Gap Analyzer (CF-04) berjalan. Pattern Engine promote ke STABLE. Future AI: Multi-model orchestration (bila diperlukan), dengan pemilihan model berdasarkan karakteristik tugas, bukan vendor tertentu. RAG (Retrieval-Augmented Generation) menggunakan CP-04 Vector

Store untuk fetch spesifik trade dari L0 tanpa membanjiri context window. Fine Tuning: Fine-tune model proprietary berdasarkan percakapan terbaik (yang lolos human eval) untuk menurunkan biaya inferensi dan meningkatkan konsistensi tone. How – Urutan Evolusi Urutan ini tidak bisa dibalik: Memory (Context) → Guardrail (Safety) → Coaching (Value) → Fine-Tuning (Efficiency). Anda tidak bisa melatih coach jika belum punya data memory. Anda tidak bisa deploy coach jika belum punya guardrail.

Best Practice Jangan tergoda untuk menambah jumlah Pattern (CP-02) terlalu cepat. 4 pattern MVP (Revenge, Deviation, Time-based, Overtrading) sudah cukup. Lebih baik 4 pattern yang confidence-nya akurat daripada 20 pattern yang noisy.

Trade-off Fine-tuning memberikan hasil paling konsisten dan murah, tapi membuat sistem kurang adaptif terhadap perubahan market psikologi. Prompt Engineering (template) lebih mahal per request tapi bisa diubah dalam hitungan detik tanpa retrain. Tunda fine-tuning sampai produk menemukan voice yang final.

Recommendation AI Roadmap harus tunduk pada Development Roadmap (Bab 26). Tim AI tidak boleh mengembangkan fitur L2 Digest jika backend Fase 1 belum stabil menangan L0. Sinkronisasi dilakukan di akhir setiap sprint.

Dengan revisi ini, AI Specification Bible 10 Bab sekarang benar-benar rapi, vendor-agnostic, dan terikat erat ke single source of truth (Context Builder & Dev Roadmap). Status: LOCKED v1.0 🔥